

RAG: Aumentando o Conhecimento do LLM

Problema: LLMs são limitados ao seu treinamento e não podem responder sobre dados privados ou recentes (ex: Documentos Internos, Regras do Projeto Alpha).

Objetivo: Mostrar como o RAG resolve a "alucinação" e a falta de conhecimento.


Integrantes:

Gustavo G Calabrez

Pedro H Papa

Cauã Barchi

Bruno da Silva



Pipeline RAG: Implementação com Hugging Face

Descreva o pipeline em 3 etapas:



Indexação

Texto do documento \rightarrow **Embeddings** (usando SentenceTransformer do Hugging Face).



Retrieval (Busca)

Pergunta do usuário é vetorizada e busca o **contexto relevante** no index (FAISS).



Generation (Geração)

O LLM (google/flan-t5-small do Hugging Face) usa o contexto recuperado para formular a resposta.

Resultados Práticos e Aprendizado

Demonstração

Pergunta

"Quem faz parte da equipe de desenvolvimento do Projeto Alpha?"

Resposta do LLM

Baseada no **contexto recuperado** dos documentos internos.

Conclusão

O RAG é crucial para criar aplicações de IA **precisas**, **atuais** e **confiáveis** em dados internos/privados.